

Likelihood-based inference for generalized linear mixed models

Inference with the R package `glmm`

(Knudson et al., 2020)

Ananda Rivas e Isabelle Sannier

Sumário

INTRODUÇÃO

MODELOS LINEARES MISTOS GENERALIZADOS

APROXIMAÇÃO DA VEROSSIMILHANÇA POR MONTE CARLO

UTILIZANDO O PACOTE GLMM DO R

DESEMPENHO E COMPARAÇÃO

NOTAS DE PROGRAMAÇÃO E IMPLEMENTAÇÃO

DISCUSSÃO E CONCLUSÃO

Introdução

Aqui é a introdução.

Descrição do modelo

Aqui é a explicação do modelo misto.

O exemplo da salamandra

Aqui é a explicação exemplo.

O conjunto de dados da salamandra

Aqui é a explicação do dataset.

O modelo da salamandra

Aqui é a explicação do modelo.

A função de verossimilhança

Aqui...

Cálculo do MCLA: Motivação

- **A Verossimilhança Marginal em GLMMs:** O cálculo exato exige resolver a integral de alta dimensão:

$$L(\theta \mid y) = \int_{\mathbb{R}^q} f_\beta(y \mid u)\, f_\nu(u)\, du$$

- **A Barreira Dimensional:**
  - Em modelos com efeitos aleatórios cruzados, a dimensão q cresce rapidamente com o tamanho da amostra.
  - *Exemplo prático:* No célebre experimento das salamandras, $q = 120$.

Consequência: Os métodos tradicionais de quadratura (como quadratura gaussiana) tornam-se computacionalmente inviáveis ou falham devido à alta dimensionalidade.

Cálculo do MCLA: Fundamentação e Vantagens

- **Reescrita via Amostragem de Importância:** Em vez de quadratura em grelha, reescrevemos o problema como uma esperança matemática sob uma densidade proposta $\tilde{f}(u)$:

$$L(\theta \mid y) = \int \frac{f_\beta(y \mid u) f_\nu(u)}{\tilde{f}(u)} \tilde{f}(u)\, du = E_{\tilde{f}} \left[\frac{f_\theta(u, y)}{\tilde{f}(u)} \right]$$

- **Vantagem Fundamental:** Como a densidade proposta $\tilde{f}(u)$ **não depende** do parâmetro de interesse θ, a derivação e a otimização sob o sinal de somatório tornam-se diretas.

Resultado: Transforma um problema de integração intratável em um problema de simulação estocástica eficiente.

O Estimador e o Gradiente

- Dado um conjunto de amostras pseudo-aleatórias $u_1, u_2, \dots, u_m \sim \tilde{f}(u)$, a aproximação Monte Carlo da Verossimilhança (MCLA) é:

$$L_m(\theta \mid y) = \frac{1}{m} \sum_{k=1}^{m} \frac{f_\theta(u_k, y)}{\tilde{f}(u_k)}$$

- O vetor Score (Gradiente) e a matriz Hessiana aproximados são calculados exatamente por:

$$\nabla_\theta \log L_m(\theta \mid y) = \frac{\frac{1}{m} \sum_{k=1}^{m} \frac{\nabla_\theta f_\theta(u_k, y)}{\tilde{f}(u_k)}}{L_m(\theta \mid y)}$$

Por que Pacotes Anteriores Falhavam?

- O pacote `bernor` (Sung & Geyer, 2007) implementava MCLA usando uma densidade de amostragem $\tilde{f}(u) = f_{\nu_0}(u)$, baseada apenas na distribuição a priori dos efeitos aleatórios.
- **O Colapso da Variância:**
  - Se $\tilde{f}(u)$ não estiver centrada onde a verossimilhança posterior $f_\theta(u \mid y)$ é alta, os pesos de importância explodem em poucos pontos.
  - A amostra efetiva colapsa e o erro padrão de Monte Carlo torna-se infinito ou impraticável.

Requisito Prático: Para funcionar na prática, $\tilde{f}(u)$ deve depender obrigatoriamente dos dados observados y e imitar o comportamento da distribuição condicional $f_\theta(u \mid y)$.

Implementação no glmm: A Mistura Tripla

- Para resolver a falha de estabilidade, Knudson et al. (2020) propuseram uma densidade de importância composta por uma **mistura de 3 distribuições**:

$$\tilde{f}(u) = w_1\, g_1(u) + w_2\, g_2(u) + w_3\, g_3(u)$$

onde por padrão $w_1 = w_2 = w_3 = 1/3$.

1. **Componente 1 (g_1 - Normal PQL):** Centrada na predição PQL $\hat{u}_{PQL}$, com matriz de covariância $\hat{\Omega}_{PQL}$.
2. **Componente 2 (g_2 - Normal Curvatura Local):** Centrada em $\hat{u}_{PQL}$, com covariância dada pela inversa da Hessiana de $-\log f_\theta(u, y)$.
3. **Componente 3 (g_3 - t de Student de Caudas Pesadas):** Centrada na origem (0), escala PQL e 5 graus de liberdade.

Papel Estratégico de Cada Componente

Componente	Construção	Função Principal
g_1: Normal PQL	Média $\widehat{u}_{PQL}$, Var $\widehat{\Omega}_{PQL}$	Localiza alta probabilidade posterior
g_2: Normal Hessiana	Média $\widehat{u}_{PQL}$, Var $(-\mathcal{H})^{-1}$	Ajusta a curvatura local exata
g_3: t-Student ($df = 5$)	Média 0, Escala $\widehat{\Omega}_{PQL}$	Proteção contra caudas leves

Garantia Teórica: A inclusão da componente g_3 impede que a razão de amostragem de importância vá para o infinito nas caudas, garantindo variância finita.

Propriedades Assintóticas: Convergência

- **Teorema de Convergência Pontual (Geyer, 1994):** Para qualquer valor fixo de θ, sob condições de integrabilidade tipo Wald:

$$L_m(\theta \mid y) \xrightarrow{m \to \infty} L(\theta \mid y) \quad \text{quase certamente (a.s.)}$$

- **Convergência Uniforme:** Se o espaço paramétrico Θ for compacto, a aproximação converge uniformemente:

$$\sup_{\theta \in \Theta} |L_m(\theta \mid y) - L(\theta \mid y)| \xrightarrow{a.s.} 0 \quad \text{quando } m \to \infty$$

Consistência do MCMLE

- **Estimador MCMLE:** Seja $\hat{\theta}_m = \arg\max_{\theta \in \Theta} L_m(\theta \mid y)$ o estimador de máxima verossimilhança Monte Carlo.
- **Consistência Fortíssima:** À medida que m cresce:

$$\hat{\theta}_m \xrightarrow{a.s.} \hat{\theta}_{MLE} \quad \text{quando } m \to \infty$$

  onde $\hat{\theta}_{MLE}$ é o verdadeiro estimador frequentista.
- **Preservação de Perfis:** Os perfis de verossimilhança MC convergem quase certamente para os perfis exatos, viabilizando testes de razão de verossimilhança.

Erro Padrão Monte Carlo (MCSE)

- Pelo Teorema Central do Limite para Amostragem de Importância:

$$\sqrt{m}\left(\hat{\theta}_m - \hat{\theta}_{MLE}\right) \xrightarrow{d} N\left(0,\, V_{MC}\right)$$

- A matriz de covariância V_{MC} é estimada no pacote `glmm` por:

$$\hat{V}_{MC} = \mathcal{I}_m(\hat{\theta}_m)^{-1}\left[\frac{1}{m}\sum_{k=1}^{m} w_k^2\, \nabla_\theta \log f_{\hat{\theta}_m}(u_k, y) \nabla_\theta \log f_{\hat{\theta}_m}(u_k, y)^T\right] \mathcal{I}_m(\hat{\theta}_m)^{-1}$$

onde w_k são os pesos normalizados.

Formatação dos Dados para o Pacote glmm

- **Estruturação de Variáveis no R:** Para ajustar modelos no pacote `glmm`, os dados precisam estar organizados em um `data.frame` com classes específicas:
  - **Efeitos Fixos (X):** Variáveis numéricas ou fatores (`factor`).
  - **Efeitos Aleatórios (Z):** Obrigatoriamente especificados como fatores (`factor`).
- **Famílias Suportadas:**
  - `bernoulli.glmm`: Resposta binária (0 ou 1).
  - `poisson.glmm`: Contagens inteiras não-negativas.
  - `binomial.glmm`: Matriz de duas colunas contendo o número de sucessos e fracassos.

Sintaxe de Ajuste com a Função glmm()

- O modelo da salamandra é ajustado especificando os efeitos fixos e a lista de efeitos aleatórios:

```
library(glmm)
data(salamander)

# Configuração de cluster paralelo (recomendado)
clust <- parallel::makeCluster(4)
set.seed(1234)

# Ajuste do Modelo com 1 milhão de simulações Monte Carlo
sal <- glmm(Mate ~ 0 + Cross,
            random = list(~ 0 + Female, ~ 0 + Male),
            varcomps.names = c("F", "M"),
            data = salamander,
            family.glmm = bernoulli.glmm,
            m = 10^6,
            cluster = clust)
```

Análise da Saída: summary(sal)

- A função `summary()` resume os parâmetros fixos e as componentes de variância:

Efeito Fixo	**Estimativa**	**Erro Padrão (SE)**	**Valor z**	**p-valor**
CrossR/R	1.000	0.384	2.600	0.0093
CrossR/W	0.320	0.390	0.823	0.4103
CrossW/R	-1.940	0.454	-4.263	< 0.0001
CrossW/W	1.010	0.434	2.333	0.0197
Comp. Variância	**Estimativa**	**Erro Padrão (SE)**	**Valor z**	**p-valor (1-cauda)**
F (Fêmea)	1.340	0.518	2.597	0.0047
M (Macho)	1.240	0.565	2.190	0.0143

Matriz de Covariância e Teste de Wald

- **Extração da Matriz de Covariância:** O comando `vcov(sal)` retorna a matriz $\widehat{\Sigma}_\theta$ completa.
- **Teste de Hipótese para Efeitos de Cruzamento:**

$$H_0 : \beta_{R/R} = \beta_{R/W} = \beta_{W/R} = \beta_{W/W}$$

- Calculando a estatística de Wald no R:

$$W = (L\hat{\beta})^T \left(L\text{Var}(\hat{\beta})L^T \right)^{-1} (L\hat{\beta}) \sim \chi^2_3$$

Resultado do Teste: $W = 39.8$, p-valor $< 1.6 \times 10^{-8}$. Rejeita-se H_0, confirmando diferença altamente significativa na probabilidade de acasalamento entre os tipos de cruzamento.

Avaliação dos Erros Padrão Monte Carlo (MCSE)

- É essencial distinguir as duas fontes de variabilidade reportadas pelo pacote:
  1. **SE (`se(sal)`):** Erro padrão amostral (assintótico dos dados).
  2. **MCSE (`mcse(sal)`):** Erro padrão devido à simulação estocástica de Monte Carlo.

Erro	$\hat{\beta}_{R/R}$	$\hat{\beta}_{R/W}$	$\hat{\beta}_{W/R}$	$\hat{\beta}_{W/W}$	$\hat{v}_F$	$\hat{v}_M$
SE Amostral	0.3844	0.3945	0.4543	0.4344	0.5177	0.5650
MCSE ($m = 10^6$)	0.0074	0.0136	0.0173	0.0219	0.0384	0.0389

Diagnóstico de Precisão: Como MCSE $\ll$ SE para todos os parâmetros, o esforço computacional $m = 10^6$ é adequado e o erro de simulação é insignificante.

Métodos Auxiliares do glmm

- `coef(sal)`: Retorna apenas o vetor estimado de efeitos fixos $\widehat{\beta}$.
- `varcomps(sal)`: Retorna o vetor estimado das componentes de variância $\widehat{\nu}$.
- `confint(sal)`: Calcula os intervalos de confiança assintóticos (ex.: 95

```
# Intervalos de confiança de 95% para todos os parâmetros
confint(sal, level = 0.95)
```

- **Intervalos de Razão de Verossimilhança:** Perfis obtidos iterativamente sobre a grade do parâmetro de interesse.

Comparação de Métodos de Inferência em GLMMs

- **Diferenças Fundamentais de Abordagem:**

Método	Paradigma	Inocuidade Computacional	Propriedade Teórica
PQL (`glmmPQL`)	Aproximado	Muito alta / Rápido	Sem verossimilhança exata; viés acentuado em caudas
AGHQ (`glmer`)	Quadratura	Limitado a poucas dimensões	Inviável para efeitos cruzados ($q = 120$)
MCMC Bayesiano	Bayesiano	Exige especificação de Priors	Amostragem pesada; convergência lenta
MCLA (`glmm`)	**Frequentista**	**Escala bem em q elevado**	**MCMLE $\xrightarrow{a.s.}$ MLE exato**

Vantagem Competitiva: O pacote `glmm` preenche a lacuna de permitir inferência frequentista **exata** via máxima verossimilhança em modelos complexos onde a quadratura gaussiana falha devido à alta dimensionalidade.

Avaliação do Esforço Computacional (m)

- **Comportamento do MCSE com o tamanho da amostra Monte Carlo (m):**
  - O erro padrão de Monte Carlo diminui na taxa $O(m^{-1/2})$.
  - Aumentar m de 10^4 para 10^6 reduz o MCSE em um fator de 10.
- **Recomendação Prática de Trabalho:**
  1. **Fase Exploratória:** Utilizar $m = 10^4$ para ajustes rápidos e checagem de código.
  2. **Fase Final de Publicação:** Utilizar $m = 10^5$ a $m = 10^6$ para garantir MCSE $< 1\% \times$ SE.

Arquitetura Interna do Pacote glmm

- **Integração R / C++:**
  - As rotinas intensivas de amostragem e avaliação da densidade da mistura tripla são implementadas em **C++** via `Rcpp` e `RcppArmadillo`.
  - Isso garante ganho de desempenho computacional em ordens de grandeza durante as somatórias de Monte Carlo.
- **Paralelização Nativa:**
  - O suporte ao pacote `parallel` permite dividir a geração dos m pontos entre múltiplos núcleos da CPU.
  - Escalabilidade quase linear com o número de cores disponíveis.

Principais Contribuições do Artigo

- **Solução para um Problema Histórico:** Supera a instabilidade numérica de abordagens anteriores de MCLA (como o pacote `bernor`) através da densidade de mistura tripla.
- **Rigor Teórico e Prático:** Oferece estimadores de máxima verossimilhança frequentistas consistentes e assintoticamente normais para GLMMs com efeitos aleatórios cruzados.
- **Disponibilidade no R:** Pacote `glmm` amigável e integrado ao ecossistema do R, permitindo cálculo direto de erros padrão de Monte Carlo (MCSE) e matrizes de covariância.

Conclusão: O pacote `glmm` consolida a aproximação por Monte Carlo como uma ferramenta robusta, viável e teoricamente fundamentada para inferência em modelos lineares mistos generalizados de alta dimensão.

Referências Bibliográficas

- Knudson, A., Geyer, C. J., & Sung, Y. J. (2020). Likelihood-based inference for generalized linear mixed models: Inference with the R package glmm. *Stat*, 10(1), e339.
- Geyer, C. J. (1994). On the convergence of Monte Carlo maximum likelihood estimates. *Bernoulli*, 1-28.
- Sung, Y. J., & Geyer, C. J. (2007). Monte Carlo likelihood inference for missing data models. *Annals of Statistics*, 35(3), 990-1011.
- Breslow, N. E., & Clayton, D. G. (1993). Approximate inference in generalized linear mixed models. *Journal of the American Statistical Association*, 88(421), 9-25.

Obrigada!

Perguntas e Discussão