

Likelihood-based inference for generalized linear mixed models

Inference with the R package `glmm`

(Knudson et al., 2020)

Ananda Rivas e Isabelle Sannier

SUMÁRIO

INTRODUÇÃO

MODELOS LINEARES MISTOS GENERALIZADOS

O EXEMPLO DA SALAMANDRA

APROXIMAÇÃO DA VEROSSIMILHANÇA POR MONTE CARLO

UTILIZANDO O PACOTE GLMM DO R

DESEMPENHO E COMPARAÇÃO

NOTAS DE PROGRAMAÇÃO E IMPLEMENTAÇÃO

DISCUSSÃO E CONCLUSÃO

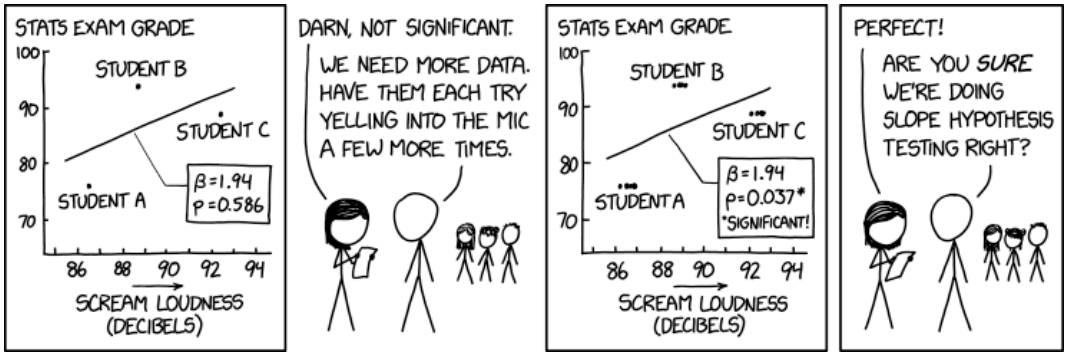
Introdução

- **Modelos Lineares (LM):** Pressupõem respostas contínuas gaussianas e observações independentes.
- **Modelos Lineares Generalizados (MLG / GLM):**
  - Estendem o LM para a **família exponencial** de distribuições (Binomial, Poisson, Gamma, etc.).
  - Relacionam a média ao preditor linear por uma **função de ligação** $g(\mu) = X\beta$.
- **A Limitação Crítica dos MLGs:**
  - Exigem a suposição de **independência marginal** entre todas as observações.
  - Em aplicações reais, dados agrupados, medidas repetidas ou amostragens multinível violam essa suposição.

Dados Correlacionados e o Risco de Pseudorreplicação

- **Exemplo Longitudinal:** Visita anual de um paciente ao médico ao longo de 10 anos $(y_{i1}, \dots, y_{i10})$.
  - As respostas do mesmo indivíduo são historicamente correlacionadas.
- **Pseudorreplicação:**
  - Tratar $N = n \times k$ medições repetidas como observações independentes infla falsamente o tamanho amostral efetivo.
  - Subestima os erros-padrão dos coeficientes, gerando p-valores artificialmente baixos e **falsos positivos (Erro Tipo I)**.

Ilustração: O Perigo dos Testes de Hipótese Incorretos



Repetir medições no mesmo sujeito não adiciona tanta informação independente quanto adicionar novos sujeitos.

A Evolução da Modelagem Estatística

Modelo	Resposta (Y)	Estrutura dos Dados	Preditor Linear
LM	Gaussiana (Contínua)	Independentes	$\mu = X\beta$
GLM	Família Exponencial	Independentes	$g(\mu) = X\beta$
LMM	Gaussiana (Contínua)	Correlacionados (Agrupados)	$E[Y\|U] = X\beta + ZU$
GLMM	Família Exponencial	Correlacionados (Agrupados)	$g(E[Y\|U]) = X\beta + ZU$

- **GLMM (Generalized Linear Mixed Model):** Unifica a flexibilidade de distribuições não-gaussianas dos MLGs com a capacidade dos LMMs de modelar correlações via **efeitos aleatórios**.

O Desafio Computacional dos GLMMs e o Artigo

- **O Obstáculo Histórico:**
  - Em LMMs, os efeitos aleatórios podem ser integrados analiticamente.
  - Em GLMMs, a verossimilhança marginal envolve uma **integral sem solução em forma fechada**.
- **Limitação dos Softwares Existentes:**
  - Métodos como Quadratura Gaussiana ou Aproximações de Laplace falham ou têm alto viés quando os efeitos aleatórios são **cruzados** (*crossed*).
- **Contribuição de Knudson et al. (2020):** Apresenta o pacote `glmm` no R, com inferência frequentista baseada em verossimilhança para GLMMs com distribuições binomial ou de Poisson, incluindo o cálculo da informação de Fisher, testes de hipóteses e a construção de intervalos de confiança baseados em verossimilhança. Trata-se do único software disponível publicamente que realiza, de forma precisa, a inferência baseada em verossimilhança para GLMMs que envolvem tanto efeitos aleatórios aninhados quanto cruzados.

Modelos Lineares Mistos Generalizados (GLMM)

Seja $Y = (Y_1, \dots, Y_n)'$ o vetor de respostas e $U = (U_1, \dots, U_q)'$ o vetor de efeitos aleatórios.

1. **Distribuição Condicional:** Dado $U = u$, as respostas $Y_1, \dots, Y_n$ são **condicionalmente independentes** com densidade na família exponencial:

$$f(y_i|u) = \exp\left\{\frac{y_i\xi_i - b(\xi_i)}{a_i(\phi)} + c(y_i, \phi)\right\}$$

2. **Preditor Linear Misto:**

$$\eta_i = x_i'\beta + z_i'u \quad \Rightarrow \quad \eta = X\beta + ZU$$

   - $X_{n\times p}$: matriz de delineamento dos **efeitos fixos** (β).
   - $Z_{n\times q}$: matriz de delineamento dos **efeitos aleatórios** (U).

3. **Função de Ligação Canônica:** $\mu_i = E(Y_i|U = u) = b'(\xi_i)$ e $g(\mu_i) = \eta_i$. Sob ligação canônica, $\xi_i = \eta_i$.

Distribuição dos Efeitos Aleatórios

- Assume-se que o vetor de efeitos aleatórios segue uma distribuição Normal multivariada com média zero:

$$U \sim \mathcal{N}_q(0, D(\nu))$$

- No pacote `glmm`, os efeitos aleatórios são assumidos mutuamente independentes, resultando em uma matriz de covariância **diagonal**:

$$D(\nu) = \text{diag}(\nu_1, \nu_2, ..., \nu_q)$$

onde os componentes do vetor ν são as variâncias das subpopulações de efeitos aleatórios.

Casos Especiais Frequentes

- **Modelo Logístico Misto:**
  - Ligação canônica: Logit.

$$\text{logit}(p_i) = \log\left(\frac{p_i}{1-p_i}\right) = x_i'\beta + z_i'u, \quad Y_i|u \sim \text{Bernoulli}(p_i)$$

- **Modelo Poisson Misto:**
  - Ligação canônica: Log.

$$\log(\lambda_i) = x_i'\beta + z_i'u, \quad Y_i|u \sim \text{Poisson}(\lambda_i)$$

Função de Verossimilhança no GLMM

A verossimilhança marginal dos parâmetros $\theta = (\beta', \nu')'$ é obtida integrando os efeitos aleatórios u fora da densidade conjunta:

$$L(\theta|y) = \int_{\mathbb{R}^q} f_\beta(y|u) f_\nu(u)\, du$$

- $f_\beta(y|u) = \prod_{i=1}^{n} f_\beta(y_i|u)$: densidade condicional dos dados.
- $f_\nu(u)$: densidade conjunta a priori dos efeitos aleatórios $\mathcal{N}_q(0, D(\nu))$.

Função de Verossimilhança de Efeitos Cruzados

A verossimilhança para efeitos cruzados tem a forma (Jiang, 2007, p. 126):

$$L(\theta|y) = c \cdot (\sigma_1^2)^{-\frac{m_1}{2}} \cdot (\sigma_2^2)^{-\frac{m_2}{2}} \cdot \exp(\mu y_{\cdot\cdot}) \cdot \int \ldots \int \left[\prod_{i=1}^{m_1} \prod_{j=1}^{m_2} \{1 + \exp(\mu + u_i + v_j)\}^{-1} \right] \cdot \exp\left(\sum u_i y_{i\cdot} + \sum v_j y_{\cdot j} - \frac{1}{2\sigma_1^2} \sum u_i^2 - \frac{1}{2\sigma_2^2} \sum v_j^2 \right) du\, dv$$

Efeitos Mistos: Aninhados vs. Cruzados

Efeitos Aninhados (*Nested*):

- Ocorrem quando níveis de um fator existem apenas dentro de um nível específico de outro fator.
- *Exemplo:* Alunos aninhados dentro de turmas, que estão aninhadas dentro de escolas.

Efeitos Cruzados (*Crossed*):

- Ocorrem quando níveis de um fator combinam-se com múltiplos níveis de outro fator.
- *Exemplo:* Fatores Fêmea e Macho em um experimento de acasalamento; ou Sujeito e Item em testes psicológicos.

Definição Formal de Efeitos Cruzados via Teoria dos Grafos

Conforme Knudson et al. (2020, Seção 2.1):

1. Considere um grafo onde cada nó representa um componente do vetor de efeitos aleatórios U.
2. Conecte dois nós por uma aresta se alguma observação Y_i no vetor de respostas depender simultaneamente desses dois efeitos aleatórios.
3. **Critério:** Se cada **subgrafo conexo maximal** contiver múltiplos nós provenientes de **diferentes componentes de variância**, os efeitos aleatórios são **cruzados**.

Efeitos Cruzados $\Longrightarrow$ Impossibilidade de fatorar a verossimilhança em integrais 1D!

O Exemplo da Salamandra (McCullagh & Nelder, 1989)

Contexto Biológico:

- Estudo de especiação em duas populações geograficamente isoladas de salamandras nas Montanhas Apalaches: *Rough Butt* (R) e *White Side* (W).
- **Objetivo Científico:** Verificar se há barreira reprodutiva entre as populações ou se cruzamentos interpopulacionais têm a mesma probabilidade de sucesso.

Cruzamentos Possíveis (Fêmea / Macho):

- R/R: Fêmea Rough Butt $\times$ Macho Rough Butt
- R/W: Fêmea Rough Butt $\times$ Macho White Side
- W/R: Fêmea White Side $\times$ Macho Rough Butt
- W/W: Fêmea White Side $\times$ Macho White Side

O Exemplo da Salamandra: Desenho Experimental

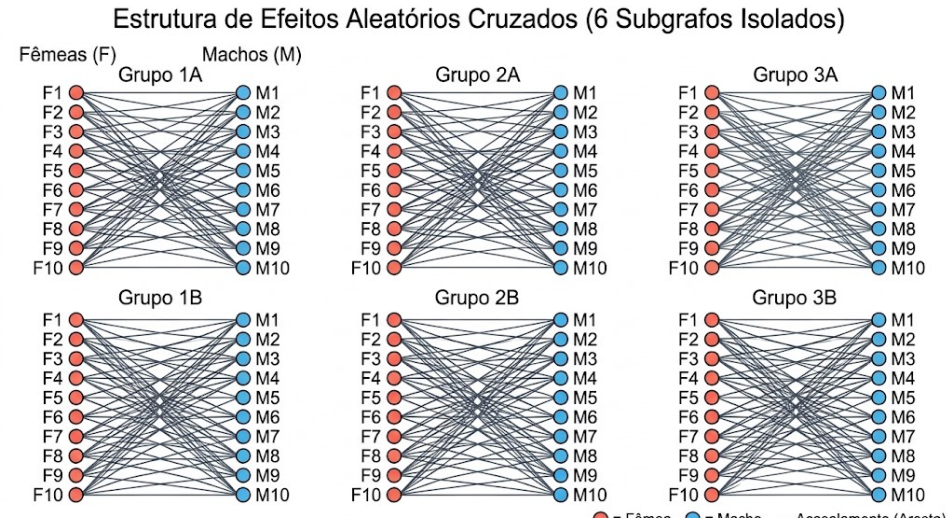
Estrutura do Experimento:

- Conduzido 3 vezes (Verão, Outono 1, Outono 2).
- Cada experimento utilizou **40 salamandras** (20 fêmeas e 20 machos), divididas em 2 grupos fechados de 20.
- Cada grupo continha: 5 Fêmeas R, 5 Fêmeas W, 5 Machos R e 5 Machos W.

Ensaios de Acasalamento:

- Cada fêmea foi pareada com 6 machos distintos do seu grupo (3 machos R e 3 machos W).
- 60 ensaios por grupo $\times$ 2 grupos por experimento $\times$ 3 experimentos = **360 observações binárias**.
- **Consequência:** Como fêmeas e machos se cruzam repetidamente, os efeitos aleatórios das Fêmeas e dos Machos são **cruzados**.

O Exemplo da Salamandra: Grafo do Experimento



O Conjunto de Dados da Salamandra no R

```
data(salamander)
head(salamander, n = 6)
```

```
  Mate Cross Female Male
1    1   R/R     10   10
2    1   R/R     11   14
3    1   R/R     12   11
4    1   R/R     13   13
5    1   R/R     14   12
6    1   R/W     15   28
```

```
sapply(salamander, class)
```

```
     Mate     Cross    Female      Male
"numeric"  "factor"  "factor"  "factor"
```

O Modelo da Salamandra (Model A - Karim & Zeger, 1992)

Para a observação i (par fêmea-macho), a probabilidade de acasalamento π_i é modelada por:

$$\begin{aligned}\text{logit}(\pi_i) = &\beta_{R/R} I(\text{Cross}_i = R/R) + \beta_{R/W} I(\text{Cross}_i = R/W) + \\ &+ \beta_{W/R} I(\text{Cross}_i = W/R) + \beta_{W/W} I(\text{Cross}_i = W/W) + \\ &+ u_i^F + u_i^M\end{aligned}$$

Efeitos Fixos (β): Log-odds de acasalamento para cada um dos 4 tipos de cruzamento.

Efeitos Aleatórios (U):

- $u_i^F \sim \mathcal{N}(0, v_F)$: efeito individual da fêmea.
- $u_i^M \sim \mathcal{N}(0, v_M)$: efeito individual do macho.
- $u^F \perp u^M$, com variâncias v_F e v_M a serem estimadas.

Intratabilidade Numérica e Efeitos Cruzados

$$L(\theta|y) = \int_{\mathbb{R}^q} f_\beta(y|u) f_\nu(u)\, du$$

Desafio de Integração

- Se os efeitos forem **aninhados**, a integral múltipla se decompõe no produto de integrais 1-dimensionais simples (ex: Quadratura Gaussiana).
- Se os efeitos forem **cruzados** (Salamandra), a integral **NÃO** se decompõe em integrais unidimensionais.

Intratabilidade Numérica e Efeitos Cruzados

- No exemplo da salamandra, o grafo de dependências contém **6 subgrafos conexos maximais**.
- Cada subgrafo possui 20 nós de efeitos aleatórios (10 fêmeas + 10 machos).
- A verossimilhança se reduz a um produto de **6 integrais de dimensão 20**:

$$L(\theta|y) = \prod_{g=1}^{6} \int_{\mathbb{R}^{20}} \left[\prod_{i \in \text{Grupo } g} f_\beta(y_i|u^F, u^M) \right] f_{v_F}(u^F) f_{v_M}(u^M)\, du^F du^M$$

- Integrais numéricas tradicionais (ex: Quadratura de Gauss-Hermite) falham em $\mathbb{R}^{20}$.

Intratabilidade Numérica e Efeitos Cruzados

(Jiang, 2007, p. 126), a verossimilhança para efeitos cruzados tem a forma:

$$L(\theta|y) \propto \int \ldots \int \left[\prod_{i=1}^{m_1} \prod_{j=1}^{m_2} \{1 + \exp(\mu + u_i + v_j)\}^{-1} \right] . \\ \exp\left(\sum u_i y_{i\cdot} + \sum v_j y_{\cdot j} - \frac{1}{2\sigma_1^2} \sum u_i^2 - \frac{1}{2\sigma_2^2} \sum v_j^2 \right) du\, dv$$

- Para $m_1 = m_2 = 40$ (80 dimensões), o integrando envolve um produto de **1600 termos**, cada um estritamente menor que 1.
- A amostragem aleatória simples da priori gera valores numéricos praticamente nulos para o integrando em quase todo o espaço.
- **Resultado:** A Lei dos Grandes Números falha na prática e a aproximação de Monte Carlo simples resulta em zero ou estouro numérico.

Softwares Existentes vs. Pacote `glmm`

Software / Pacote	Método de Integração / Aproximação	Limitação em Efeitos Cruzados
SAS `NLMIXED`	Quadratura Gaussiana Adaptativa	Restrito a poucas dimensões e efeitos não-cruzados
R `lme4::glmer`	Aproximação de Laplace / Gauss-Hermite	Não realiza verossimilhança exata para cruzados
SAS `GLIMMIX`	PQL / Laplace por padrão	PQL produz viés severo em dados binários
R `MASS::glmmPQL`	Quase-Verossimilhança Penalizada (PQL)	Subestima os componentes de variância
R `bernor`	MCLA com amostragem fixa (independente de y)	Falha ao encontrar a MLE na Salamandra
R `glmm`	**MCLA com Amostragem por Importância Adaptativa**	**Consegue verossimilhança exata com SEs finitos!**

Cálculo do MCLA: Motivação

- **A Verossimilhança Marginal em GLMMs:** O cálculo exato exige resolver a integral de alta dimensão:

$$L(\theta \mid y) = \int_{\mathbb{R}^q} f_\beta(y \mid u)\, f_\nu(u)\, du$$

- **A Barreira Dimensional:**
  - Em modelos com efeitos aleatórios cruzados, a dimensão q cresce rapidamente com o tamanho da amostra.
  - *Exemplo prático:* No célebre experimento das salamandras, $q = 120$.

Consequência: Os métodos tradicionais de quadratura (como quadratura gaussiana) tornam-se computacionalmente inviáveis ou falham devido à alta dimensionalidade.

Cálculo do MCLA: Fundamentação e Vantagens

- **Reescrita via Amostragem de Importância:** Em vez de quadratura em grelha, reescrevemos o problema como uma esperança matemática sob uma densidade proposta $\tilde{f}(u)$:

$$L(\theta \mid y) = \int \frac{f_\beta(y \mid u) f_\nu(u)}{\tilde{f}(u)} \tilde{f}(u)\, du = E_{\tilde{f}} \left[\frac{f_\theta(u, y)}{\tilde{f}(u)} \right]$$

- **Vantagem Fundamental:** Como a densidade proposta $\tilde{f}(u)$ **não depende** do parâmetro de interesse θ, a derivação e a otimização sob o sinal de somatório tornam-se diretas.

Resultado: Transforma um problema de integração intratável em um problema de simulação estocástica eficiente.

O Estimador e o Gradiente

- Dado um conjunto de amostras pseudo-aleatórias $u_1, u_2, \dots, u_m \sim \tilde{f}(u)$, a aproximação Monte Carlo da Verossimilhança (MCLA) é:

$$L_m(\theta \mid y) = \frac{1}{m} \sum_{k=1}^{m} \frac{f_\theta(u_k, y)}{\tilde{f}(u_k)}$$

- O vetor Score (Gradiente) e a matriz Hessiana aproximados são calculados exatamente por:

$$\nabla_\theta \log L_m(\theta \mid y) = \frac{\frac{1}{m} \sum_{k=1}^{m} \frac{\nabla_\theta f_\theta(u_k, y)}{\tilde{f}(u_k)}}{L_m(\theta \mid y)}$$

Por que Pacotes Anteriores Falhavam?

- O pacote `bernor` (Sung & Geyer, 2007) implementava MCLA usando uma densidade de amostragem $\tilde{f}(u) = f_{\nu_0}(u)$, baseada apenas na distribuição a priori dos efeitos aleatórios.
- **O Colapso da Variância:**
  - Se $\tilde{f}(u)$ não estiver centrada onde a verossimilhança posterior $f_\theta(u \mid y)$ é alta, os pesos de importância explodem em poucos pontos.
  - A amostra efetiva colapsa e o erro padrão de Monte Carlo torna-se infinito ou impraticável.

Requisito Prático: Para funcionar na prática, $\tilde{f}(u)$ deve depender obrigatoriamente dos dados observados y e imitar o comportamento da distribuição condicional $f_\theta(u \mid y)$.

Implementação no glmm: A Mistura Tripla

- Para resolver a falha de estabilidade, Knudson et al. (2020) propuseram uma densidade de importância composta por uma **mistura de 3 distribuições**:

$$\tilde{f}(u) = w_1\, g_1(u) + w_2\, g_2(u) + w_3\, g_3(u)$$

onde por padrão $w_1 = w_2 = w_3 = 1/3$.

1. **Componente 1 (g_1 - Normal PQL):** Centrada na predição PQL $\widehat{u}_{PQL}$, com matriz de covariância $\widehat{\Omega}_{PQL}$.
2. **Componente 2 (g_2 - Normal Curvatura Local):** Centrada em $\widehat{u}_{PQL}$, com covariância dada pela inversa da Hessiana de $-\log f_\theta(u, y)$.
3. **Componente 3 (g_3 - t de Student de Caudas Pesadas):** Centrada na origem (0), escala PQL e 5 graus de liberdade.

Papel Estratégico de Cada Componente

Componente	Construção	Função Principal
g_1: Normal PQL	Média $\widehat{u}_{PQL}$, Var $\widehat{\Omega}_{PQL}$	Localiza alta probabilidade posterior
g_2: Normal Hessiana	Média $\widehat{u}_{PQL}$, Var $(-\mathcal{H})^{-1}$	Ajusta a curvatura local exata
g_3: t-Student ($df = 5$)	Média 0, Escala $\widehat{\Omega}_{PQL}$	Proteção contra caudas leves

Garantia Teórica: A inclusão da componente g_3 impede que a razão de amostragem de importância vá para o infinito nas caudas, garantindo variância finita.

Propriedades Assintóticas: Convergência

- **Teorema de Convergência Pontual (Geyer, 1994):** Para qualquer valor fixo de θ, sob condições de integrabilidade tipo Wald:

$$L_m(\theta \mid y) \xrightarrow{m \to \infty} L(\theta \mid y) \quad \text{quase certamente (a.s.)}$$

- **Convergência Uniforme:** Se o espaço paramétrico Θ for compacto, a aproximação converge uniformemente:

$$\sup_{\theta \in \Theta} |L_m(\theta \mid y) - L(\theta \mid y)| \xrightarrow{a.s.} 0 \quad \text{quando } m \to \infty$$

Consistência do MCMLE

- **Estimador MCMLE:** Seja $\hat{\theta}_m = \arg\max_{\theta \in \Theta} L_m(\theta \mid y)$ o estimador de máxima verossimilhança Monte Carlo.
- **Consistência Fortíssima:** À medida que m cresce:

$$\hat{\theta}_m \xrightarrow{a.s.} \hat{\theta}_{MLE} \quad \text{quando } m \to \infty$$

  onde $\hat{\theta}_{MLE}$ é o verdadeiro estimador frequentista.
- **Preservação de Perfis:** Os perfis de verossimilhança MC convergem quase certamente para os perfis exatos, viabilizando testes de razão de verossimilhança.

Erro Padrão Monte Carlo (MCSE)

- Pelo Teorema Central do Limite para Amostragem de Importância:

$$\sqrt{m}\left(\hat{\theta}_m - \hat{\theta}_{MLE}\right) \xrightarrow{d} N\left(0,\, V_{MC}\right)$$

- A matriz de covariância V_{MC} é estimada no pacote `glmm` por:

$$\hat{V}_{MC} = \mathcal{I}_m(\hat{\theta}_m)^{-1}\left[\frac{1}{m}\sum_{k=1}^{m} w_k^2\, \nabla_\theta \log f_{\hat{\theta}_m}(u_k, y) \nabla_\theta \log f_{\hat{\theta}_m}(u_k, y)^T\right] \mathcal{I}_m(\hat{\theta}_m)^{-1}$$

onde w_k são os pesos normalizados.

Formatação dos Dados para o Pacote glmm

- **Estruturação de Variáveis no R:** Para ajustar modelos no pacote `glmm`, os dados precisam estar organizados em um `data.frame` com classes específicas:
  - **Efeitos Fixos (X):** Variáveis numéricas ou fatores (`factor`).
  - **Efeitos Aleatórios (Z):** Obrigatoriamente especificados como fatores (`factor`).
- **Famílias Suportadas:**
  - `bernoulli.glmm`: Resposta binária (0 ou 1).
  - `poisson.glmm`: Contagens inteiras não-negativas.
  - `binomial.glmm`: Matriz de duas colunas contendo o número de sucessos e fracassos.

Sintaxe de Ajuste com a Função glmm()

- O modelo da salamandra é ajustado especificando os efeitos fixos e a lista de efeitos aleatórios:

```
library(glmm)
data(salamander)

# Configuração de cluster paralelo (recomendado)
clust <- parallel::makeCluster(4)
set.seed(1234)

# Ajuste do Modelo com 1 milhão de simulações Monte Carlo
sal <- glmm(Mate ~ 0 + Cross,
            random = list(~ 0 + Female, ~ 0 + Male),
            varcomps.names = c("F", "M"),
            data = salamander,
            family.glmm = bernoulli.glmm,
            m = 10^6,
            cluster = clust)
```

Análise da Saída: summary(sal)

- A função `summary()` resume os parâmetros fixos e as componentes de variância:

Efeito Fixo	**Estimativa**	**Erro Padrão (SE)**	**Valor z**	**p-valor**
CrossR/R	1.000	0.384	2.600	0.0093
CrossR/W	0.320	0.390	0.823	0.4103
CrossW/R	-1.940	0.454	-4.263	< 0.0001
CrossW/W	1.010	0.434	2.333	0.0197
Comp. Variância	**Estimativa**	**Erro Padrão (SE)**	**Valor z**	**p-valor (1-cauda)**
F (Fêmea)	1.340	0.518	2.597	0.0047
M (Macho)	1.240	0.565	2.190	0.0143

Matriz de Covariância e Teste de Wald

- **Extração da Matriz de Covariância:** O comando `vcov(sal)` retorna a matriz $\hat{\Sigma}_\theta$ completa.
- **Teste de Hipótese para Efeitos de Cruzamento:**

$$H_0 : \beta_{R/R} = \beta_{R/W} = \beta_{W/R} = \beta_{W/W}$$

- Calculando a estatística de Wald no R:

$$W = (L\hat{\beta})^T \left(L\text{Var}(\hat{\beta})L^T \right)^{-1} (L\hat{\beta}) \sim \chi^2_3$$

Resultado do Teste: $W = 39.8$, p-valor $< 1.6 \times 10^{-8}$. Rejeita-se H_0, confirmando diferença altamente significativa na probabilidade de acasalamento entre os tipos de cruzamento.

Avaliação dos Erros Padrão Monte Carlo (MCSE)

- É essencial distinguir as duas fontes de variabilidade reportadas pelo pacote:
  1. **SE (`se(sal)`):** Erro padrão amostral (assintótico dos dados).
  2. **MCSE (`mcse(sal)`):** Erro padrão devido à simulação estocástica de Monte Carlo.

Erro	$\hat{\beta}_{R/R}$	$\hat{\beta}_{R/W}$	$\hat{\beta}_{W/R}$	$\hat{\beta}_{W/W}$	$\hat{v}_F$	$\hat{v}_M$
SE Amostral	0.3844	0.3945	0.4543	0.4344	0.5177	0.5650
MCSE ($m = 10^6$)	0.0074	0.0136	0.0173	0.0219	0.0384	0.0389

Diagnóstico de Precisão: Como MCSE $\ll$ SE para todos os parâmetros, o esforço computacional $m = 10^6$ é adequado e o erro de simulação é insignificante.

Métodos Auxiliares do glmm

- `coef(sal)`: Retorna apenas o vetor estimado de efeitos fixos $\widehat{\beta}$.
- `varcomps(sal)`: Retorna o vetor estimado das componentes de variância $\widehat{\nu}$.
- `confint(sal)`: Calcula os intervalos de confiança assintóticos (ex.: 95

```
# Intervalos de confiança de 95% para todos os parâmetros
confint(sal, level = 0.95)
```

- **Intervalos de Razão de Verossimilhança:** Perfis obtidos iterativamente sobre a grade do parâmetro de interesse.

Comparação de Métodos de Inferência em GLMMs

- **Diferenças Fundamentais de Abordagem:**

Método	Paradigma	Inocuidade Computacional	Propriedade Teórica
PQL (`glmmPQL`)	Aproximado	Muito alta / Rápido	Sem verossimilhança exata; viés acentuado em caudas
AGHQ (`glmer`)	Quadratura	Limitado a poucas dimensões	Inviável para efeitos cruzados ($q = 120$)
MCMC Bayesiano	Bayesiano	Exige especificação de Priors	Amostragem pesada; convergência lenta
MCLA (`glmm`)	**Frequentista**	**Escala bem em q elevado**	**MCMLE $\xrightarrow{a.s.}$ MLE exato**

Vantagem Competitiva: O pacote `glmm` preenche a lacuna de permitir inferência frequentista **exata** via máxima verossimilhança em modelos complexos onde a quadratura gaussiana falha devido à alta dimensionalidade.

Avaliação do Esforço Computacional (m)

- **Comportamento do MCSE com o tamanho da amostra Monte Carlo (m):**
  - O erro padrão de Monte Carlo diminui na taxa $O(m^{-1/2})$.
  - Aumentar m de 10^4 para 10^6 reduz o MCSE em um fator de 10.
- **Recomendação Prática de Trabalho:**
  1. **Fase Exploratória:** Utilizar $m = 10^4$ para ajustes rápidos e checagem de código.
  2. **Fase Final de Publicação:** Utilizar $m = 10^5$ a $m = 10^6$ para garantir MCSE $< 1\% \times$ SE.

Arquitetura Interna do Pacote glmm

- **Integração R / C++:**
  - As rotinas intensivas de amostragem e avaliação da densidade da mistura tripla são implementadas em **C++** via `Rcpp` e `RcppArmadillo`.
  - Isso garante ganho de desempenho computacional em ordens de grandeza durante as somatórias de Monte Carlo.
- **Paralelização Nativa:**
  - O suporte ao pacote `parallel` permite dividir a geração dos m pontos entre múltiplos núcleos da CPU.
  - Escalabilidade quase linear com o número de cores disponíveis.

Principais Contribuições do Artigo

- **Solução para um Problema Histórico:** Supera a instabilidade numérica de abordagens anteriores de MCLA (como o pacote `bernor`) através da densidade de mistura tripla.
- **Rigor Teórico e Prático:** Oferece estimadores de máxima verossimilhança frequentistas consistentes e assintoticamente normais para GLMMs com efeitos aleatórios cruzados.
- **Disponibilidade no R:** Pacote `glmm` amigável e integrado ao ecossistema do R, permitindo cálculo direto de erros padrão de Monte Carlo (MCSE) e matrizes de covariância.

Conclusão: O pacote `glmm` consolida a aproximação por Monte Carlo como uma ferramenta robusta, viável e teoricamente fundamentada para inferência em modelos lineares mistos generalizados de alta dimensão.

Referências Bibliográficas

- Breslow, N. E., & Clayton, D. G. (1993). Approximate inference in generalized linear mixed models. *Journal of the American Statistical Association*, 88(421), 9-25.
- Geyer, C. J. (1994). On the convergence of Monte Carlo maximum likelihood estimates. *Bernoulli*, 1-28.
- JIANG, J. Generalized Linear Mixed Models. New York: Springer, 2007. p. 126.
- Knudson, A., Geyer, C. J., & Sung, Y. J. (2020). Likelihood-based inference for generalized linear mixed models: Inference with the R package glmm. *Stat*, 10(1), e339.
- McCULLAGH, P.; NELDER, J. A. Generalized Linear Models. 2. ed. London: Chapman & Hall, 1989.
- Sung, Y. J., & Geyer, C. J. (2007). Monte Carlo likelihood inference for missing data models. *Annals of Statistics*, 35(3), 990-1011.

Obrigada!

Perguntas e Discussão